



《深度学习》核心笔记： 从数学基础到机器学习原理

第一章：前言 (Introduction)

核心主题：深度学习的本质、历史背景及其在人工智能中的定位。

AI之挑战：对人类而言易于执行，但难以形式化描述的任务。

1. 核心定义与动机

- **深度学习的定义**：一种通过层次化的概念体系（Hierarchical Concepts）来解释世界的机器学习方法。它通过组合简单的概念来构建复杂的概念。让计算机从经验中学习，并根据层次化的概念体系来理解世界。

- 为什么要深度学习：

- 传统AI的局限：基于硬编码规则（如专家系统）难以处理现实世界中主观、直观的知识（如图像识别、自然语言理解）。（如何将非形式化的知识传达给计算机）

- **表示学习**：使用深度学习来发掘表示本身。让计算机自动从原始数据中提取特征（Representation），而非由人工设计特征。（例如decoder, encoder）

- 深度 vs. 浅层：深度模型通过多步指令（计算图）或深层概念图，能够处理更复杂的非线性问题。深度学习通过其他较简单的表示来表示复杂表示，解决了表示学习中的核心问题。

2. 历史趋势与关键节点

20th 40s~60s: 控制论 (Cybernetics)
20th 80s~90s: 联结主义 (Connectionism)
2006→now: Deep Learning

- 三起三落：

1. 控制论 (1940s-1960s)：McCulloch-Pitts神经元、感知机。因无法解决XOR问题 (Minsky & Papert, 1969) 而衰落。

2. 连接主义 (1980s-1990s)：反向传播算法 (Backpropagation) 出现，解决多层网络训练

问题。受限于算力和数据再次衰落。

3. 深度学习复兴 (2006-至今)：Hinton提出深度信念网络（DBN）的贪心逐层训练，算力提升（GPU）和大数据爆发推动了第三次浪潮。

- 关键驱动力：

- 数据量：互联网时代数据呈指数级增长（ImageNet等）。
- 模型规模：神经网络规模随算力提升每2.4年翻倍。
- 精度提升：在计算机视觉、语音识别、NLP等领域超越传统方法甚至人类表现。

4. 循环神经网络：用于对序列和其他序列间的关系进行建模，引领了机器翻译，并引出LLM等。

神经图灵机（2014）：能学习读取存储单元和向存储单元写入任意内容。

5. 强化学习：智能体通过试错来执行学习任务。

第二章：线性代数 (Linear Algebra)

核心主题：深度学习的数学语言，用于高效处理多维数组和线性变换。

1. 基础概念

- 标量 (Scalar)：0维张量，单个数值。
- 向量 (Vector)：1维数组，可视为空间中的点。
- 矩阵 (Matrix)：2维数组， $A \in \mathbb{R}^{m \times n}$ 。
- 张量 (Tensor)：超过2维的数组。
- 转置 (Transpose)：矩阵的行列互换， $(A^T)_{i,j} = A_{j,i}$ 。

2. 矩阵运算

- 矩阵乘法：核心运算， $C = AB$ 。要求A的列数等于B的行数。不满足交换律，但满足结合律和分配律。
- 广播 (Broadcasting)：允许矩阵与向量相加（向量隐式复制到矩阵每一行）。
- 单位矩阵 (Identity)： I_n ，满足 $AI = A$ ，主对角线为1。
- 逆矩阵 (Matrix Inverse)： A^{-1} 满足 $A^{-1}A = I$ 。仅方阵且列向量线性无关时存在。

3. 范数与特殊矩阵

- 范数 (Norm)：衡量向量大小。
 - L^2 范数 (欧几里得范数)： $|x|_2 = \sqrt{\sum_i x_i^2}$ 。
 - L^1 范数：用于产生稀疏解， $|x|_1 = \sum_i |x_i|$ 。
 - L^∞ 范数 (Max Norm)：最大绝对值。
 - Frobenius 范数：矩阵的欧几里得范数。
- 对角矩阵：仅主对角线有非零元素。
- 对称矩阵： $A = A^T$ 。
- 正交矩阵：行和列标准正交， $A^{-1} = A^T$ 。

4. 特征分解与SVD

- 特征分解 (Eigendecomposition)：将矩阵分解为特征值和特征向量。仅适用于方阵。

- $Av = \lambda v$, $A = V \text{diag}(\lambda) V^{-1}$ 。
- **奇异值分解 (SVD)**：适用于任意矩阵， $A = UDV^T$ 。
 - U ：左奇异向量 (AA^T 的特征向量)。
 - V ：右奇异向量 (A^TA 的特征向量)。
 - D ：奇异值矩阵。
- **伪逆 (Moore-Penrose Pseudoinverse)**：用于非方矩阵求逆， $A^+ = VD^+U^T$ 。

5. 应用：主成分分析 (PCA)

- **流程**：计算质心—去均值—协方差矩阵—特征值分解—旋转坐标轴—取得主成分
 - **目的**：降维，保留数据主要变化方向。
 - **方法**：通过计算协方差矩阵 X^TX 的特征向量，选取最大特征值对应的特征向量作为投影方向。
- 通过正交变换将一组可能相关的变量转换为少数几个不相关变量（主成分）的统计方法。

第三章：概率与信息论

(Probability and Information Theory)

核心主题：处理不确定性、建模数据生成过程及量化信息。

概率论使我们能够提出不确定的声明以及在不确定性存在的情况下进行推理，信息论使我们能够量化概率分布中的不确定性总量。

频率派概率：直接与事件发生的频率相联系。
贝叶斯概率：用概率表示一种信任度，涉及不确定性水平。

1. 概率论基础

- 随机变量：离散或连续，取值具有不确定性。
- 概率分布：
 - PMF (概率质量函数)：离散变量（如Bernoulli, Multinoulli）。
 - PDF (概率密度函数)：连续变量（如高斯分布/正态分布）。
- 边缘概率： $P(x) = \sum_y P(x,y)$ 或 $\int p(x,y) dy$ 。
- 条件概率： $P(y|x) = \frac{P(x,y)}{P(x)}$ 。
- 独立性： $P(x,y) = P(x)P(y)$ ；条件独立： $P(x,y|z) = P(x|z)P(y|z)$ 。

2. 关键公式与分布

- 贝叶斯规则 (Bayes' Rule)： $P(x|y) = \frac{P(y|x)P(x)}{P(y)}$ 。用于从先验和似然推导后验概率。
- 期望与方差：
 - 期望： $E[f(x)] = \sum P(x)f(x)$ 。
 - 方差： $\text{Var}\{f(x)\} = E[(f(x) - E[f(x)])^2]$ 。
- 协方差：衡量两个变量的线性相关性。
- 常用分布：
 - 高斯分布：中心极限定理使其成为默认选择。
 - 指数分布 & Laplace分布：用于处理尖峰数据。
 - Dirac Delta：用于表示经验分布 (Empirical Distribution)。

3. 信息论

- 自信息 (Self-information)： $I(x) = -\log P(x)$ ，衡量单个事件的信息量。

- 香农熵 (Shannon Entropy) : 分布的平均不确定性, $H(x) = -E[\log P(x)]$ 。
- KL散度 (Kullback-Leibler Divergence) : 衡量两个分布的差异, $D_{\text{KL}}(P \mid Q) = E_{x \sim P} [\log \frac{P(x)}{Q(x)}]$ 。
 - 非负, 非对称。
- 交叉熵 (Cross-Entropy) : $H(P, Q) = H(P) + D_{\text{KL}}(P \mid Q)$ 。常用于分类任务的损失函数。

4. 结构化概率模型

- 图模型 : 用图结构描述变量间的依赖关系。
 - 有向图 (Directed) : 表示条件概率, $p(x) = \prod_i p(x_i \mid \text{Pa}_G(x_i))$ 。
 - 无向图 (Undirected) : 表示团上的因子乘积, $p(x) = \frac{1}{Z} \prod_i \phi^{(i)}(C^{(i)})$ 。

第四章：数值计算 (Numerical Computation)

核心主题：算法在计算机上的实际执行，解决数值不稳定和优化效率问题。

1. 数值稳定性挑战

- 下溢 (Underflow)：接近零的数被舍入为零（如导致除零错误）。
- 上溢 (Overflow)：极大数被舍入为无穷大。
- Softmax 函数：典型例子，需通过减去最大值 ($z = x - \max_i x_i$) 来避免溢出。

2. 病态条件数 (Condition Number)

- 定义：矩阵最大和最小特征值的模之比。
- 意义：衡量矩阵求逆对输入误差的敏感度。条件数大意味着矩阵是病态的 (ill-conditioned)，微小扰动导致巨大误差。

3. 基于梯度的优化

- 导数与梯度：梯度指向函数增长最快的方向，负梯度指向下降最快的方向。
- 梯度下降 (Gradient Descent)：迭代更新 $x' = x - \epsilon \nabla f(x)$ 。
- 临界点：梯度为零的点，包括局部极小值、局部极大值和鞍点。
- 二阶导数 (Hessian)：衡量曲率。
 - 牛顿法：利用二阶泰勒展开， $x^* = x^{(0)} - H^{-1} \nabla f(x)$ 。收敛快，但在鞍点附近可能失效。
- 约束优化：
 - KKT条件：处理等式和不等式约束的通用方法。
 - 拉格朗日乘子：将约束问题转化为无约束的广义拉格朗日函数求解。

第五章：机器学习基础 (Machine Learning Basics)

核心主题：什么是学习？如何构建模型以解决实际问题。

本章旨在探讨构建深度学习系统所需的核心原理，包括学习算法的定义、泛化能力、过拟合与欠拟合、超参数调节以及最大似然估计等核心概念。

5.1 学习算法 (Learning Algorithms)

定义 (Mitchell, 1997):

一个计算机程序被称为从经验 E 中学习，是指针对某类任务 T 和性能度量 P ，它通过经验 E 改进了在这些任务上的性能。

核心要素：

- 任务 T ：机器学习系统应该如何处理样本（如分类、回归）。
- 性能度量 P ：用于评估系统表现好坏的指标（如准确率、错误率）。
- 经验 E ：训练模型所用的数据集。

5.1.1 任务 T

机器学习任务通常由如何处理样本定义：

样本：我们从某些希望机器学习系统处理的对象或事件中收集到的已经量化的特征。

- 分类 (Classification)：预测离散的类别标签。
 - 输出：函数 $f: \mathcal{R}^n \rightarrow \{1, \dots, k\}$ 。
 - 拓展：输入缺失分类（需学习联合概率分布以处理缺失特征）。先考虑整体概率分布，再把不重要的缺失项边缘化。
- 回归 (Regression)：预测连续数值。
 - 输出：函数 $f: \mathcal{R}^n \rightarrow \mathcal{R}$ 。
 - 应用：预测保险索赔金额、证券价格。
- 转录 (Transcription)：将非结构化数据（如音频、图像）转化为离散文本序列。

- 应用：语音识别、OCR（光学字符识别）。
- 机器翻译 (Machine Translation)：输入一种语言的符号序列，输出另一种语言的符号序列。
- 结构化输出 (Structured Output)：输出包含多个相互关联元素的结构（如语法树、像素级分割图）。
- 异常检测 (Anomaly Detection)：识别与正常模式显著偏离的样本（如信用卡欺诈检测）。
- 合成与采样 (Synthesis and Sampling)：生成与训练数据相似的新样本（如生成逼真图像、语音合成）。
- 缺失值填补 (Missing Value Imputation)：预测样本中缺失的特征值。
- 去噪 (Denoising)：根据被噪声破坏的输入 $\tilde{x}$ ，预测干净样本 x 。
- 密度估计 (Density Estimation)：学习概率分布函数 $p_{\text{model}}(x)$ ，以描述数据的生成机制。

5.1.2 性能度量 P

- 分类/回归任务：通常直接使用准确率 (Accuracy) 或错误率 (Error Rate)。
- 密度估计任务：通常使用对数似然 (Log-likelihood) 作为性能度量，因为它直接衡量了模型对数据分布的拟合程度。
- 泛化 (Generalization)：衡量模型在未观测数据（测试集）上的性能，这是机器学习的核心目标。

5.1.3 经验 E

- 无监督学习 (Unsupervised Learning)：训练含有很多特征的数据集，然后学习出这个数据集上有用的结构性质。仅观察随机向量 x 的样本，试图学习其概率分布 $p(x)$ 或结构性质（如聚类、密度估计）。
 $\hookrightarrow$ 无标签算法在无指导情况下自行理解数据。

- 监督学习 (Supervised Learning)：观察样本 x 及其对应的标签 y ，学习映射 $p(y|x)$ 。

★ 无监督学习与监督学习间界限模糊。

- 无监督问题可拆分为 n 个监督问题： $P(x) = \prod_{i=1}^n p(x_i | x_1, \dots, x_{i-1})$ 。
 - 求解监督问题时，也可以先用无监督学习联合分布 $P(x, y)$ ，再推断 $P(y|x) = \frac{P(x, y)}{\sum_y P(x, y)}$ 。

- 半监督学习 (Semi-supervised Learning)：部分样本有标签，部分没有。
- 强化学习 (Reinforcement Learning)：通过与环境交互获得奖励信号进行学习（本章未深入）。

5.2 容量、过拟合和欠拟合 (Capacity,

Overfitting, and Underfitting)

核心矛盾：如何在训练误差和测试误差之间取得平衡。

训练集和测试集：通过数据集上被称为数据生成过程的概率分布生成。通常我们会做一系列独立同分布假设（每个数据集中的样本都是彼此独立的，且训练集与测试集是同分布的，共享数据生成分布。）

- 欠拟合 (Underfitting)：模型在训练集上表现不佳，未能捕捉数据的基本规律（偏差大）。
- 过拟合 (Overfitting)：模型在训练集上表现极好，但在测试集上表现糟糕，记住了数据中的噪声而非规律（方差大）。
- 泛化误差 (Generalization Error)：模型在新数据上的期望误差。

容量：指模型拟合各种函数的能力。一种控制训练算法容量的方法是选择假设空间。

- VC维：定义为该分类器能够分类的训练样本的最大数目。
 - 非参数模型：参数模型学习的函数在观测到新数据前，参数向量的分量个数是有限且固定的。非参数模型则没有这些限制。（例：最近邻回归，也可以将参数学习算法嵌入到另一个增加参数数目的算法来创建非参数学习算法）
 - 贝叶斯误差：机器学习理论上所能达到的最低可能预测误差，源于数据本身固有的噪声。
- 训练误差可以低于贝叶斯误差，因为训练算法有能力记住训练集中特定的样本。测试误差一般都高于贝叶斯误差。

5.2.1 没有免费午餐定理 (No Free Lunch Theorem)


- 含义：脱离特定的数据分布，没有单一的机器学习算法在所有问题上都优于其他算法。
- 启示：算法的优劣取决于它是否适用于我们关心的问题。我们必须根据具体问题（数据的先验假设）来选择或设计模型。

5.2.2 正则化 (Regularization)

- 定义：在保留模型拟合能力的同时，限制其复杂度，以防止过拟合的技术。
- 目的：通过引入额外的偏好（如偏好更小的权重），从多个可能的解中选择一个泛化能力更好的解。

- 常见方法：权重衰减（L2正则化）、Dropout、提前终止等。

5.3 超参数和验证集 (Hyperparameters and Validated Sets)



超参数 (Hyperparameters) vs. 模型参数 (Parameters)

- 模型参数：通过训练数据自动学习得到的参数（如权重矩阵 W ）。
- 超参数：在训练前必须人为设定的参数，控制着学习过程或模型结构（如学习率 α 、正则化系数 λ 、网络层数）。

☆若要训练超参数，需要一个训练算法观测不到的验证集用来估计训练前或训练后的泛化误差，更新超参数。

5.3.1 交叉验证 (Cross-Validation)

- 目的：在数据有限的情况下，更可靠地评估模型超参数的性能。
- 方法：将数据集分成 k 个子集（折），轮流使用其中 $k-1$ 个子集训练，剩下的 1 个子集验证，最终取平均性能。

问题：无法精确算出模型平均误差的方差。
无法准确评估模型的准确性。

5.4 估计、偏差和方差 (Estimators, Bias, and Variance)

5.4.1 点估计 (Point Estimation)

- 目标：使用训练集 D 估计未知参数 θ ，得到估计值 $\hat{\theta}$ 。

函数估计也是函数空间中的一个点估计。

5.4.2 偏差 (Bias)

- 定义：估计量的期望值与真实参数值之间的差异。
- 公式： $\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta$ 。
- 偏差-方差分解：泛化误差可以分解为偏差、方差和不可约减误差之和。

- 高偏差：模型过于简单，导致欠拟合。

- 高方差：模型过于复杂，导致过拟合。→ 无偏估计并不总是最好的估计。

5.4.3 方差和标准误差 (Variance and Standard Error)

- 方差：衡量估计值 $\hat{\theta}$ 在不同数据集上的波动程度。
- 标准误差： $\sqrt{\text{Var}(\hat{\theta})}$ 。

5.4.4 权衡偏差和方差以最小化均方误差

- 目标：寻找偏差和方差的“甜蜜点” (Sweet Spot) 。
- 图解：随着模型容量增加，偏差下降，方差上升，均方误差 (MSE) 呈现 U 形曲线。

$$\begin{aligned} \text{MSE} &= E[(\hat{\theta}_m - \theta)^2] \\ &= \text{Bias}(\hat{\theta}_m)^2 + \text{Var}(\hat{\theta}_m) \end{aligned}$$

5.4.5 一致性 (Consistency)

- 定义：当样本数量 $m \rightarrow \infty$ 时，估计量 $\hat{\theta}_m$ 收敛于真实值 θ 的性质。
- 弱一致性：依概率收敛。
- 强一致性：以概率 1 收敛。

5.5 最大似然估计 (Maximum Likelihood Estimation)

核心思想：选择能使观测数据出现概率最大的参数值。

公式：

$$\theta_{\text{ML}} = \arg\max_{\theta} \sum_{i=1}^m \log P_{\text{model}}(x^{(i)}; \theta)$$

5.5.1 条件对数似然和均方误差

- 在监督学习中，MLE 通常应用于条件分布 $P(y|x)$ 。
- 线性回归的推导：假设噪声服从高斯分布，MLE 等价于最小化均方误差 (MSE)。
 - $p(y|x) = \mathcal{N}(y; \hat{y}(x; \omega), \sigma^2)$ 。
 - 最大化该似然函数等价于最小化 $\sum_{i=1}^m (y^{(i)} - f(x^{(i)}; \theta))^2$ 。

$$\theta_{\text{ML}} = \arg\max_{\theta} P(Y|X; \theta)$$

5.5.2 最大似然的性质

- 一致性：MLE 通常是参数的一致估计量。
- 偏差：在有限样本下，MLE 可能是有偏的（如方差估计）。

- 贝叶斯观点：MLE 等价于最小化模型分布与真实分布之间的 KL 散度。

5.6 贝叶斯统计 (Bayesian Statistics)

核心区别：频率学派（参数是固定的） vs. 贝叶斯学派（参数是随机变量，具有先验分布）。

贝叶斯统计用概率反映知识状态的不确定性程度。再观察到数据前，我们将 θ 的已知知识表示成先验概率分布，然后结合数据求出后验恢复数据对我们关于 θ 新年的影响。

$$\underbrace{p(\theta | x^{(1)}, \dots, x^{(m)})}_{\text{后验}} = \frac{\overbrace{p(x^{(1)}, \dots, x^{(m)} | \theta)}^{\text{数据似然}} \underbrace{p(\theta)}_{\text{先验}}}{p(x^{(1)}, \dots, x^{(m)})}$$

先验开始是相对均匀的概率分布或高熵的高斯分布，观测数据通常使后验的熵下降，并集中在参数的几个可能性很高的值。

在训练数据很有限时，贝叶斯统计通常能泛化地更好，但当训练样本数目很大，通常会有很大的计算代价。

5.6.1 最大后验 (MAP) 估计

原则上我们应该使用参数 θ 的完整贝叶斯后验分布进行预测，但这样的计算往往很复杂。为此单点估计常常也是需要的，它提供一个可行的近似解。

- 定义：结合先验知识 $P(\theta)$ 和观测数据 $P(x|\theta)$ ，寻找后验概率最大的参数。

- 公式：
$$\theta_{\text{MAP}} = \arg\max_{\theta} p(\theta|x) = \arg\max_{\theta} \log p(x|\theta) + \log p(\theta).$$

- 意义：MAP 等价于在 MLE 基础上增加了一个正则化项（由先验分布决定）。例如，高斯先验等价于 L2 正则化。

5.7 监督学习算法 (Supervised Learning Algorithms)

监督学习算法：给定一组输入 x 和输出 y 的训练集，学习如何关联输入输出。

5.7.1 概率监督学习

- 判别学习：直接学习决策函数 $f(x)$ 或条件概率 $P(y|x)$ 。

- 生成学习：学习联合概率分布 $P(x, y)$ ，然后通过贝叶斯规则推导 $P(y|x)$ 。

逻辑回归：使用logistic sigmoid函数将线性输出压缩到 $(0, 1)$ 区间，该值可以解释为概率：

$$p(y=1|x; \theta) = \sigma(\theta^T x)$$

5.7.2 支持向量机 (SVM)

支持向量机类似于逻辑回归，也是基于线性函数，但它不输出概率，只输出类别。如正类负类，就是用一条直线来分隔。
一般取分界线上的样本作为支持向量。

- 核心机制：寻找最大间隔超平面 (Maximum Margin Hyperplane) 。

- 正则化：通过引入松弛变量 (Slack Variables) 处理不可分数据，对应 L1 正则化。

- 核技巧 (Kernel Trick)：将数据映射到高维空间以解决非线性问题。完全等价于先用 $\phi(x)$ 处理数据，再在新的转换空间内学习线性模型。使用核技巧的方法被称为核机器或核方法。

核函数：将低维空间数据隐式映射到高维特征空间的关键工具。

最常用的核函数是高斯和，也被称为径向基函数。

$$k(u, v) = \mathcal{N}(u - v; 0, \sigma^2 I)$$

将数据从低维空间映射到高维的函数

$$K(x, x') = \phi(x) \cdot \phi(x')$$

我们可以认为高斯和在执行一种模版匹配，训练标签 y 相关的样本 x 变为类别 y 的模版，若 x' 与 x 接近，该模型会赋予 y 以较大的权重。

5.7.3 其他简单的监督学习算法

- K近邻 (K-Nearest Neighbors, KNN)：基于局部性假设，计算复杂度高，属于“懒惰学习”。

K最近邻 (KNN) 是一种简单直观的监督学习算法，常用于分类和回归。它的核心思想是“物以类聚”：

预测一个新样本时，就看它在特征空间中最近的 K 个“邻居”是什么样子。

工作原理：

1. 计算新样本与所有已知样本的距离（常用欧氏距离）。
2. 按距离排序，选出最近的 K 个点。
3. 分类时，这 K 个点中哪个类别最多，新样本就归为哪类（投票制）。
4. 回归时，则取这 K 个点的平均值作为预测值。

关键影响要素：

- K值：太小容易受噪声影响（过拟合），太大则可能忽略细节（欠拟合）。通常用交叉验证来选取合适的 K 。
- 距离度量：最常用欧氏距离，但根据数据特点也可用曼哈顿距离、闵氏距离等。

优点：非常简单，无需训练过程，可解释性强。

缺点：预测慢（需扫描全部数据）、内存占用大、对高维数据效果差（维度灾难）。

- 线性回归：基础的回归算法。
- 决策树/随机森林：基于规则的分类器。


≈

5.8 无监督学习算法 (Unsupervised Learning Algorithms)

5.8.1 主成分分析 (PCA)

- 目的：降维，保留数据中方差最大的方向。

PCA学习一种比原始输入更低维的表示，也学习了一种元素间彼此没有线性相关的表示。（使方差的主坐标和新表示空间的基对齐，原始表示空间中方差最大的方向和新空间的轴对齐。）



- 原理：通过特征值分解协方差矩阵 $X^T X$ ，选取前 k 个最大特征值对应的特征向量作为投影方向。
- 假设：数据的主要变化方向是线性的。

5.8.2 k-均值聚类 (k-Means Clustering)

- 目的：将数据划分为 k 个簇。
- 算法流程：

1. 随机初始化 k 个质心。
2. 将每个样本分配给最近的质心。
3. 更新质心为簇内样本的均值。
4. 重复 2-3 直到收敛。

- 目标函数：最小化簇内平方误差 (Distortion Function) 。

注意针对不同的属性，最好将它们分别聚类，不然会丢失一些相似性信息（拥有相同属性的样本被分到不同的类中）。

5.9 随机梯度下降 (Stochastic Gradient Descent, SGD)

核心优化算法：

- 批量梯度下降 (Batch GD)：每次更新使用整个训练集，计算代价大。
- 随机梯度下降 (SGD)：每次更新仅使用一个样本（或一个小批量 minibatch）。
 - 优点：计算速度快，内存效率高，适合大规模数据。
 - 缺点：更新方向带有噪声，路径震荡，但有时有助于逃离局部极小值。
- 收敛性：只要学习率适当衰减，SGD 可以收敛到局部极小值。

5.10 构建机器学习算法 (Building a Machine Learning Algorithm)

通常由三部分组成：

1. 代价函数 (Cost Function)：通常是负的对数似然（对应 MLE）加上正则化项。
2. 优化过程：通常使用梯度下降或其变体（如 SGD）。（迭代数值优化近似最小化目标）
3. 模型假设：如线性模型 $y = x^T w$ 或神经网络。

5.11 推动深度学习的挑战 (Challenges Driving Deep Learning)

传统机器学习方法在处理高维数据时面临以下核心挑战，推动了深度学习的发展：

5.11.1 维数灾难 (Curse of Dimensionality)

- 现象：随着维度增加，空间体积呈指数级增长，导致数据变得极度稀疏。机器学习问题变得相当困难。
- 后果：需要指数级增长的数据量才能维持相同的泛化误差。
- 深度学习的解法：利用深层结构的组合性 (Compositionality)，用较少的参数描述复杂的高维函数。

5.11.2 局部不变性和平滑正则化

- 传统方法假设： $f(x + \varepsilon) \approx f(x)$ （平滑性假设）。

局部不变性作用：利用未标记数据挖掘数据的内在几何结构，避免模型在数据稀疏区域剧烈震荡。

- 问题：在高维空间中，现实世界的任务（如图像分类）往往不是平滑的。微小的像素变化（如光照、旋转）可能导致类别完全改变。

- 深度学习的解法：不假设平滑性，而是通过学习特征来捕捉本质变化因素（Factors of Variation）。

平滑正则化（Smoothness Regularization）

· 含义：在损失函数中加入惩罚项，迫使模型函数在输入空间（或数据流形上）光滑。

例如权重衰减方法。

· 作用：通过惩罚函数的变化率，抑制过拟合，提升泛化性能。

5.11.3 流形学习 (Manifold Learning)

流形指连接在一起的区域。流形学习是一类降维方法。

- 流形假设：高维数据实际上集中在低维的流形结构上（例如，所有“猫”的图片在像素空间中形成一个低维子空间）。

- 目标：深度网络旨在学习将输入数据映射到低维流形的坐标，从而简化分类或回归任务。

-与“局部不变性+平滑正则化”的关系

· 局部不变性正是流形学习的基础假设：相近的点（在流形上）应具有相近的低维表示或输出。

· 平滑正则化在半监督学习中利用流形假设：在数据流形上，标签函数应光滑变化。此时流形学习提供的邻接图或测地距离直接用于构造正则项（如拉普拉斯正则化）。

-典型应用

· 高维数据可视化（如用t-SNE看MNIST聚类）

· 数据预处理，减少冗余特征

· 半监督学习、图像识别、基因表达分析

需要注意：流形学习对噪声敏感，且通常只能用于训练集（新样本的映射需专门处理）。